

Rachunek prawdopodobieństwa 2R

Kycia

Spis rozmaitości treściowalnych

06.10.23 : Warunkowa wartość oczekiwana	3
1.1. Prawdopodobieństwo warunkowe	3
1.2. Konstrukcja warunkowej wartości oczekiwanej	3
1.3. Prawdopodobieństwo warunkowe	6
09.10.23 : Własności WWO	8
2.1. Istnienie i jedyność	8
2.2. Własności wwo	10

Wykład 06.10.23 : Warunkowa wartość oczekiwana

1.1 Prawdopodobieństwo warunkowe

Tak jak zwykle do tej pory, pracować będziemy na przestrzeni probabilistycznej $(\Omega, \mathcal{F}, \mathbb{P})$.

Przypomnijmy definicję **prawdopodobieństwa warunkowego** z Rachunku Prawdopodobieństwa 1 (i z liceum). Dla zdarzenia $A \in \mathcal{F}$ takiego, że $\mathbb{P}[A] \in (0, 1)$ definiujemy prawdopodobieństwo warunkowe jako

$$\mathbb{P}[B | A] = \frac{\mathbb{P}[A \cap B]}{\mathbb{P}[A]}.$$

Wartość ta informuje nas o zajściu B wtedy, gdy jesteśmy pewni, że A zaszło. Ale co, jeśli nasza wiedza dotycząca A jest mniej pewna? To znaczy, *co jeśli* $\mathbb{P}[A] = 0$? Dość naturalne wydaje się rozważenie zdarzenia przeciwnego i zsumowania obu prawdopodobieństw:

$$\mathbb{1}_A \mathbb{P}[B | A] + \mathbb{1}_{A^c} \mathbb{P}[B | A^c].$$

Zauważmy od razu, że wyrażenie $\mathbb{1}_A \mathbb{P}[B | A]$ jest zmienną losową.

W przypadku, gdy mamy dwa zbiory, $A_1, A_2 \in \mathcal{F}$, i chcemy zbadać $\mathbb{P}[B | A_1 \cap A_2]$ możemy powyższe rozumowanie rozszerzyć na wszystkie możliwe kombinacje A_1, A_2 i ich dopełnień:

$$\mathbb{1}_{A_1 \cap A_2} \mathbb{P}[B | A_1 \cap A_2] + \mathbb{1}_{A_1 \cap A_2^c} \mathbb{P}[B | A_1 \cap A_2^c] + \mathbb{1}_{A_1^c \cap A_2} \mathbb{P}[B | A_1^c \cap A_2] + \mathbb{1}_{A_1^c \cap A_2^c} \mathbb{P}[B | A_1^c \cap A_2^c].$$

Działanie jak wyżej daje pełną informację o każdym zdarzeniu z ciała generowanego przez zdarzenia A_1 i A_2 . Nazywamy je **rozbiciem** względem σ -ciała generowanego przez A_1 i A_2 .

Analogicznie możemy zdefiniować $\mathbb{E}[X | A]$ dla całkowalnej zmiennej losowej X (tzn. $\mathbb{E}[|X|] < \infty$):

$$\mathbb{E}[X | A] = \int_{\Omega} X(\omega) \mathbb{P}[d\omega | A] = \frac{1}{\mathbb{P}[A]} \mathbb{E}[X \mathbb{1}_A],$$

gdzie całka wyżej tłumaczy się na całkę po X względem miary $\mathbb{P}[B | A]$.

Uzasadnimy, dlaczego wzór wyżej jest zasadną definicją prawdopodobieństwa warunkowego przy ograniczonej wiedzy o zdarzeniu A.

1.2 Konstrukcja warunkowej wartości oczekiwanej

Zanim zdefiniujemy **warunkową wartość oczekiwaną [wwo]** zmiennej losowej X, zaczniemy od przyjrzenia się bliżej motywacji i konstrukcji stojącej za tym pojęciem.

Niech Z będzie całkowalną zmienną losową przyjmującą przeliczalnie wiele wartości. Zdefiniujemy funkcję

$$h(z) = \begin{cases} \mathbb{E}[X | Z = z] & \mathbb{P}[Z = z] > 0 \\ 0 & \text{wpp} \end{cases}$$

oraz zmienną losową $Y = h(Z)$. Weźmy dowolny $C \in \text{Bor}(\mathbb{R})$ i zbadajmy $\mathbb{E}[Y \mathbb{1}_{\{Z \in C\}}]$. Zaczniemy od skorzystania z faktu, że Z przyjmuje przeliczalnie wiele wartości, więc możemy zapisać sumę po

nich wszystkich

$$\begin{aligned}
 \mathbb{E}[Y \mathbb{1}_{\{Z \in C\}}] &= \sum_{z \in C} h(z) \mathbb{P}[Z = z] = \\
 &\stackrel{*}{=} \sum_{z \in C} \mathbb{E}[X \mathbb{1}_{\{Z=z\}}] \frac{1}{\mathbb{P}[Z = z]} \mathbb{P}[Z = z] = \\
 &= \sum_{z \in C} \mathbb{E}[X \mathbb{1}_{\{Z=z\}}] = \\
 &= \mathbb{E}\left[\sum_{z \in C} X \mathbb{1}_{\{Z=z\}}\right] = \\
 &= \mathbb{E}[X \mathbb{1}_{\{Z \in C\}}]
 \end{aligned}$$

Równość $*$ wynika ze sposobu w jaki zdefiniowaliśmy $\mathbb{E}[X | A]$ w poprzednim podrozdziale.

Zauważmy, że dowolne zdarzenie $F \in \sigma(Z)$ jest postaci $F = \{z \in C\}$ dla pewnego $C \in \text{Bor}(\mathbb{R})$. Wyprowadziliśmy więc równość:

$$\mathbb{E}[Y \mathbb{1}_F] = \mathbb{E}[X \mathbb{1}_F] \quad F \in \sigma(Z).$$

Pozostaje zapytać, co z tej zależności wynika?

Dla $F = \Omega$ dostajemy

$$\mathbb{E}[h(Z)] = \mathbb{E}[Y] = \mathbb{E}[X].$$

Dygresja.

W tym miejscu kuszące byłoby rozpisanie $Y = h(Z)$ wprost z definicji, tzn. $h(Z) = \mathbb{E}[X | Z = Z]$, ale jest to całkowitą brednią. W definicji funkcji h podanej na samym początku przykładu z jest teoretycznym punkcikiem, natomiast przy definiowaniu $Y = h(Z)$ ów Z jest już obserwowaną przez nas, konkretną zmienną losową. W takim razie, bardziej poprawny byłby zapis

$$h(Z(\omega)) = \mathbb{E}[X | \{\omega' : Z(\omega') = Z(\omega)\}].$$

Przykład(y) 1.1

1. Ze zbioru $\{1, 2, \dots, 10\}$ losujemy w sposób jednostajny liczbę i oznaczamy ją jako N . W drugim losowaniu, również w sposób jednostajny, wybieramy liczbę ze zbioru $\{1, \dots, N\}$ i nazywamy ją M . Chcemy znaleźć średnią wartość liczby M . Oczywiście, nie jest trudno zrobić to metodami poznanymi na poprzednich przygodach probabilistycznych, jednak w tym przypadku użyjemy konstrukcji wyżej.

Funkcja h będzie wyglądać następująco:

$$h(n) = \mathbb{E}[M | N = n] = \sum_{1 \leq i \leq n} \frac{i}{n} = \frac{1}{n} \cdot \frac{n(n+1)}{2} = \frac{n+1}{2}$$

czyli $h(N) = \frac{N+1}{2}$.

Stosując notację jak wyżej, mamy

$$\begin{aligned}
 Z &= N \\
 X &= M
 \end{aligned}$$

czyli podstawiając do wzoru:

$$\begin{aligned}\mathbb{E}[M] &= \mathbb{E}[h(N)] = \mathbb{E}\left[\frac{N+1}{2}\right] = \\ &= \frac{1}{2}(\mathbb{E}[N] + 1) = \frac{1}{2}\left(\sum_{1 \leq i \leq 10} \frac{i}{10} + 1\right) = \\ &= \frac{1}{2}\left(\frac{11}{2} + 1\right) \frac{13}{4}\end{aligned}$$

Rozbicie jak wyżej można w elegancki sposób zamienić w bardziej abstrakcyjną definicję warunkowej wartości oczekiwanej.

Definicja 1.1.

Niech $\mathcal{G} \subseteq \mathcal{F}$ będzie σ -ciałem, a X całkowalną zmienną losową.

Zmienną losową Y nazywamy **warunkową wartością oczekiwaną** [wwo] X pod warunkiem \mathcal{G} , jeśli następujące warunki są spełnione:

(W1) Y jest \mathcal{G} -mierzalne

(W2) $(\forall G \in \mathcal{G}) \mathbb{E}[X1_G] = \mathbb{E}[Y1_G]$

Nasuwać się teraz pytania o poprawność Y zdefiniowanego jak wyżej. Czy zawsze istnieje i czy jest on jedyny?

Przykład(y) 1.2

1. Niech $\mathcal{G} = \sigma(Z)$, gdzie Z jest zmienną losową przyjmującą przeliczalnie wiele wartości. Wówczas $Y = h(Z)$ dla $h(z) = \mathbb{E}[X | Z = z]$ jest wwo X względem \mathcal{G} .

Twierdzenie 1.1 : poprawność wwo.

Dla σ -ciała $\mathcal{G} \subseteq \mathcal{F}$ i całkowalnej zmiennej losowej X **istnieje jedyna zmienna losowa** Y będąca wwo X względem \mathcal{G} . Będziemy ją oznaczać

$$\mathbb{E}[X | \mathcal{G}] = Y.$$

Jeśli Y, Y' są wwo X względem \mathcal{G} , to $Y = Y'$ prawie wszędzie.

Dowód

Dowód na następnym wykładzie.



Uwaga 1.2.

O wwo X pod warunkiem \mathcal{G} należy myśleć jako o przybliżeniu X na podstawie informacji zawartych w \mathcal{G} (więcej na wykładzie 3).

Przykład(y) 1.3

1. Jeśli X i \mathcal{G} są niezależne, to znaczy dla każdego $B \in \text{Bor}(\mathbb{R})$ i dla każdego $G \in \mathcal{G}$ zachodzi

$$\mathbb{P}[X \in B, G] = \mathbb{P}[X \in B] \mathbb{P}[G],$$

to wtedy $\mathbb{E}[X | \mathcal{G}] = \mathbb{E}[X] = Y$.

Warunek (W1) jest oczywiście spełniony, bo Y jest funkcją stałą, więc jego przeciwobraz to całość lub \emptyset (czyli jest \mathcal{G} -mierzalny). Warunek (W2) sprawdzamy dla dowolnego $G \in \mathcal{G}$:

$$\mathbb{E}[X 1_G] = \mathbb{E}[X] \mathbb{E}[1_G] = \mathbb{E}[\mathbb{E}[X] 1_G] = \mathbb{E}[Y 1_G].$$

2. Rozważmy pokrycie Ω rozłącznymi zbiorami $\{A_n\}_{n \in \mathbb{N}}$, gdzie $A_i \in \mathcal{F}$ dla każdego i . Niech $\mathcal{G} = \sigma(A_i : i \in \mathbb{N})$ będzie σ -ciałem rozpinanym przez to pokrycie. Wówczas

$$\mathbb{E}[X | \mathcal{G}] = \sum_{i \in \mathbb{N}} 1_{A_i} \mathbb{E}[X | A_i]$$

Spełnianie pierwszego warunku jest oczywiste, bo mamy do czynienia z funkcją prostą. Warunek (W2) wystarczy sprawdzić dla atomów, czyli $G = A_j$, bo wszystkie zmienne losowe \mathcal{G} -mierzalne są stałe na A_j .

$$\begin{aligned} \mathbb{E}\left[\left(\sum 1_{A_i} \mathbb{E}[X | A_i]\right) 1_{A_j}\right] &= \mathbb{E}\left[\mathbb{E}[X | A_j] 1_{A_j}\right] = \\ &= \mathbb{E}\left[1_{A_j} \frac{\mathbb{E}[X 1_{A_j}]}{\mathbb{P}[A_j]}\right] = \\ &= \mathbb{E}\left[1_{A_j}\right] \frac{\mathbb{E}[X 1_{A_j}]}{\mathbb{P}[A_j]} = \mathbb{E}[X 1_{A_j}], \end{aligned}$$

gdyż $\mathbb{E}[1_{A_j}] = \mathbb{P}[A_j]$.

3. Jeśli w przykładzie wyżej weźmiemy $A_1 = A$, $A_2 = A^c$ i $A_3 = A_4 = \dots = \emptyset$ oraz $\mathcal{G} = \sigma(A)$, to dostajemy to samo co na samym początku tego wykładu:

$$\mathbb{E}[X | \mathcal{G}] = 1_A \mathbb{E}[X | A] + 1_{A^c} \mathbb{E}[X | A^c].$$

1.3 Prawdopodobieństwo warunkowe

Definicja 1.2 : prawdopodobieństwo warunkowe.

Dla σ -ciała $\mathcal{G} \subseteq \mathcal{F}$ definiujemy **prawdopodobieństwo warunkowe** pod warunkiem \mathcal{G} jako

$$\mathbb{P}[A | \mathcal{G}] = \mathbb{E}[1_A | \mathcal{G}]$$

Prawdopodobieństwo $\mathbb{P}[A | \mathcal{G}]$ jest zmienną losową taką, że:

🐟 $\mathbb{P}[A | \mathcal{G}]$ jest \mathcal{G} -mierzalna (ze względu na wwo w definicji)

🐟 $\mathbb{E}[\mathbb{P}[A | \mathcal{G}] 1_G] = \mathbb{E}[1_A 1_G] = \mathbb{P}[A \cap G]$

Przykład(y) 1.4

1. Niech E_1, E_2 będą niezależnymi zmiennymi losowymi z rozkładem $\exp(1)$. Chcemy się zastanowić jak wygląda prawdopodobieństwo

$$\mathbb{P} [E_1 + E_2 > t \mid \sigma(E_1)]$$

dla $t > 0$. Ponieważ liczymy to prawdopodobieństwo względem $\sigma(E_1)$, to tak naprawdę wszystkie informacje o E_1 mamy w ręku, gdyż tę zmienną obserwujemy. Czyli E_1 możemy w takim przypadku potraktować jako zwykłą stałą i zgadnąć, że

$$\mathbb{P} [E_1 + E_2 > t \mid \sigma(E_1)] = e^{-(t-E_1)}.$$

Dla pewności, przeliczymy cały ten przykład wprost z definicji, żeby przekonać się że strzał był poprawny.

Niech $G \in \sigma(E_1)$, wtedy zgodnie z wcześniejszą obserwacją istnieje pewne $C \in \text{Bor}(\mathbb{R})$ takie, że G jest postaci $G = \{E_1 \in C\}$. Policzmy $\mathbb{E} [\mathbb{P} [\{E_1 + E_2 > t\} \mid \sigma(E_1)]]$ gdyż jak wyżej zauważyliśmy, $\mathbb{P} [A \mid \mathcal{G}]$ jest zmienną losową. Mamy więc

$$\begin{aligned} \mathbb{E} [\mathbb{P} [E_1 + E_2 > t \mid \sigma(E_1)] \mathbb{1}_G] &\stackrel{*}{=} \mathbb{P} [\{E_1 + E_2 > t\} \cap G] = \\ &= \mathbb{P} [\{E_1 + E_2 > t\} \cap \{E_1 \in C\}] = \\ &= \iint_{\substack{C \times \mathbb{R}_+ \\ x+y>t}} e^{-x} e^{-y} dx dy = \\ &= \int_C e^{-x} \underbrace{\left[\int_{x+y>t} e^{-y} dy \right]}_{**} dx = \\ &= \int_C e^{-x} e^{-(t-x)+} dx = \mathbb{E} [e^{-(t-E_1)+} \mathbb{1}_{\{E_1 \in C\}}] = \mathbb{E} [e^{-(t-E_1)+} \mathbb{1}_G] \end{aligned}$$

Równość $*$ wynika z uwagi pod definicją prawdopodobieństwa warunkowego. Całka $**$ jest równa 1 gdy $x > t$ (gdyż wtedy dla każdego y mamy $x + y > t$), natomiast dla $x \leq t$ wynosi ona $e^{-(t-x)}$.

Wykład 09.10.23 : Własności WWO

Na tym wykładzie zajmiemy się dowodzeniem własności wwo, w tym pokażemy jej istnienie i jedyność.

2.1 Istnienie i jedyność

Lemat 2.1 : WWO jest całkowalna.

To znaczy, że mając całkowalną zmienną losową X oraz σ -ciało $\mathcal{G} \subseteq \mathcal{F}$, to zachodzi $\mathbb{E} [|\mathbb{E} [X | \mathcal{G}]|] < \infty$.

Dowód

Rozważmy zbiór

$$A = \{\omega : \mathbb{E} [X | \mathcal{G}] (\omega) > 0\} = \{\omega : \mathbb{E} [X | \mathcal{G}] \in (0, \infty)\} = [\mathbb{E} [X | \mathcal{G}]]^{-1} ((0, \infty))$$

jako przeciwobraz zbioru $(0, \infty) \in \text{Bor}(\mathbb{R})$ przez funkcję \mathcal{G} -mierzalną $\mathbb{E} [X | \mathcal{G}]$ wiemy, że $A \in \mathcal{G}$. Ponieważ $\mathbb{E} [X | \mathcal{G}]$ jest wwo X pod warunkiem \mathcal{G} , to musi warunek (W2):

$$0 \leq \mathbb{E} [\mathbb{E} [X | \mathcal{G}] 1_A] = \mathbb{E} [X 1_A] \leq \mathbb{E} [|X| 1_A] < \infty$$

bo X jest całkowalna.

Analogicznie postępujemy dla zbioru A^c :

$$0 \leq \mathbb{E} [-\mathbb{E} [X | \mathcal{G}] 1_{A^c}] = \mathbb{E} [-X 1_{A^c}] \leq \mathbb{E} [|X| 1_{A^c}] < \infty.$$

Zauważmy, że

$$|\mathbb{E} [X | \mathcal{G}]| = \mathbb{E} [X | \mathcal{G}] 1_A - \mathbb{E} [X | \mathcal{G}] 1_{A^c}$$

Dodając obie te nierówności (i korzystając z liniowości wartości oczekiwanej) uzyskujemy

$$0 \leq \mathbb{E} [\mathbb{E} [X | \mathcal{G}] 1_A] - \mathbb{E} [\mathbb{E} [X | \mathcal{G}] 1_{A^c}] = \mathbb{E} [\mathbb{E} [X | \mathcal{G}] 1_A - \mathbb{E} [X | \mathcal{G}] 1_{A^c}] = \mathbb{E} [|\mathbb{E} [X | \mathcal{G}]|] < \infty$$



Lemat 2.2 : jedyność p.w..

Niech $\mathcal{G} \subseteq \mathcal{F}$ będzie σ -ciałem. Jeśli Y i Y' są obie wersjami $\mathbb{E} [X | \mathcal{G}]$, to $Y = Y'$ p.w..

Dowód

Ustalmy $\varepsilon > 0$ i rozważmy zdarzenie

$$A_\varepsilon = \{Y - Y' > \varepsilon\} \in \mathcal{G}$$

które jest \mathcal{G} -mierzalne, bo Y i Y' takie są.

$$\begin{aligned} \varepsilon \mathbb{P} [A_\varepsilon] + \mathbb{E} [Y' 1_{A_\varepsilon}] &= \mathbb{E} [\varepsilon 1_{A_\varepsilon}] + \mathbb{E} [Y' 1_{A_\varepsilon}] = \\ &= \mathbb{E} [(\varepsilon + Y') 1_{A_\varepsilon}] \leq \\ &\stackrel{*}{\leq} \mathbb{E} [Y 1_{A_\varepsilon}] \stackrel{(W2)}{=} \mathbb{E} [X 1_{A_\varepsilon}] = \\ &= \mathbb{E} [Y' 1_{A_\varepsilon}] \end{aligned}$$

gdzie * wynika z tego, że na zbiorze A_ε $Y > Y' + \varepsilon$.

Dostajemy więc, że

$$\varepsilon \mathbb{P}[A_\varepsilon] + \mathbb{E}[Y' 1_{A_\varepsilon}] \leq \mathbb{E}[Y' 1_{A_\varepsilon}]$$

co po przeniesieniu \mathbb{E} na jedną stronę daje

$$\varepsilon \mathbb{P}[A_\varepsilon] \leq 0$$

a ponieważ $\varepsilon > 0$, to musi być $\mathbb{P}[A_\varepsilon] = 0$.

Wówczas

$$\mathbb{P}[Y > Y'] = \mathbb{P}\left[\underbrace{(\exists n) Y \geq Y' + \frac{1}{n}}_{\mathbb{P}\left[A_{\frac{1}{n}}\right]}\right] = \mathbb{P}\left[\bigcup A_{\frac{1}{n}}\right] = \lim \mathbb{P}\left[A_{\frac{1}{n}}\right] = 0$$

ponieważ $A_{\frac{1}{n}} \subseteq A_{\frac{1}{n+1}}$.

Zamieniając miejscami Y i Y' w dowodzie dostaniemy $\mathbb{P}[Y' > Y] = 0$, czyli obie możliwości są miary zero.



Twierdzenie 2.3 : o istnieniu WWO.

Niech $\mathcal{G} \subseteq \mathcal{F}$ będzie σ -ciałem, a X jest całkowalną zmienną losową. Istnieje zmienna losowa Y spełniająca oba postulaty wwo X pod warunkiem \mathcal{G} .

Jest to Twierdzenie 1.1 z poprzedniego wykładu.

Zanim jednak przejdziemy do dowodu 2.3, przypomnijmy *twierdzenie Radona-Nikodyma* z teorii miary:

Dygresja : twierdzenie Radona-Nikodyma.

Niech μ i ν będą σ -miarami na przestrzeni (Ω, \mathcal{G}) takimi, że ν jest *absolutnie ciągła* względem μ [$\nu \ll \mu$], tzn $\mu(A) = 0 \Rightarrow \nu(A) = 0$. Wówczas istnieje \mathcal{G} -mierzalna funkcja $f : \Omega \rightarrow \mathbb{R}$ taka, że

$$\nu(A) = \int_A f(x) \mu(dx)$$

Funkcję f jak wyżej często oznaczamy $f = \frac{d\nu}{d\mu}$ i nazywamy *pochodną Radona-Nikodyma*.

Dowód

Wracając do dowodu twierdzenia 2.3. Najpierw pokażemy prostszy przykład, gdy $X \geq 0$, a potem uogólnimy go do dowolnego X .

Załóżmy, że $X \geq 0$ p.w. Wtedy możemy rozważyć miary $\mu = \mathbb{P} \upharpoonright \mathcal{G}$ oraz $\nu(A) = \mathbb{E}[X 1_A]$. Od razu widać, że w takim ułożeniu $\nu \ll \mu$, więc na mocy twierdzenia Radona-Nikodyma istnieje f \mathcal{G} -mierzalna taka, że

$$\mathbb{E}[f 1_A] = \int_A f(\omega) \mu(d\omega) = \nu(A) - \mathbb{E}[X 1_A].$$

Funkcja f spełnia (W1) z definicji wwo, bo jest \mathcal{G} -mierzalna, a (W2) jest potwierdzone przez rachunek wyżej. Czyli f jest wwo X pod warunkiem \mathcal{G} .

Niech teraz X będzie dowolną zmienną losową. Możemy ją rozbić jako

$$X = X^+ - X^-,$$

gdzie $X^+ = \max(0, X) \geq 0$ oraz $X^- = -\min(0, X) \geq 0$. Do obu tych zmiennych możemy zastosować pierwszą część dowodu, by dostać zmienne $\mathbb{E}[X^+ | \mathcal{G}]$ oraz $\mathbb{E}[X^- | \mathcal{G}]$. Wystarczy zauważyć, że dzięki liniowości \mathbb{E} możemy w prosty sposób pokazać

$$\mathbb{E}[X | \mathcal{G}] = \mathbb{E}[X^+ | \mathcal{G}] - \mathbb{E}[X^- | \mathcal{G}]$$



2.2 Własności wwo

Twierdzenie 2.4 : o arytmetyce wwo.

Niech $\mathcal{G}, \mathcal{G}_1, \mathcal{G}_2 \subseteq \mathcal{F}$ będą σ -ciałami, a X, X_1, X_2 całkowalnymi zmiennymi losowymi

1. $\mathbb{E}[\mathbb{E}[X | \mathcal{G}]] = \mathbb{E}[X]$
2. Jeśli $X \geq 0$, to również $\mathbb{E}[X | \mathcal{G}] \geq 0$
3. $\mathbb{E}[aX_1 + bX_2 | \mathcal{G}] = a\mathbb{E}[X_1 | \mathcal{G}] + b\mathbb{E}[X_2 | \mathcal{G}]$
4. $|\mathbb{E}[X | \mathcal{G}]| \leq \mathbb{E}[|X| | \mathcal{G}]$
5. Jeśli $\mathcal{G}_1 \subseteq \mathcal{G}_2$, to wówczas

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}_1] | \mathcal{G}_2] = \mathbb{E}[\mathbb{E}[X | \mathcal{G}_2] | \mathcal{G}_1] = \mathbb{E}[X | \mathcal{G}_1]$$

To znaczy, że mając informacje o X w dwóch zawartych w sobie ciałach, to mniejsze zawsze wygrywa.

6. Jeśli Y jest \mathcal{G} -mierzalna i XY jest całkowalna, to $\mathbb{E}[XY | \mathcal{G}] = Y\mathbb{E}[X | \mathcal{G}]$, czyli Y możemy traktować jako stałą.

Dowód

1. Wystarczy wstawić $G = \Omega$ w warunek (W2):

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}]] = \mathbb{E}[\mathbb{E}[X | \mathcal{G}] \mathbf{1}_\Omega] \stackrel{(W2)}{=} \mathbb{E}[X \mathbf{1}_\Omega] = \mathbb{E}[X]$$

2. Wynika z dowodu twierdzenia o istnieniu, bo $\frac{d\nu}{d\mu} = \mathbb{E}[X | \mathcal{G}]$. Gdyby $A = \{\omega : \mathbb{E}[X | \mathcal{G}] < 0\}$, to wówczas

$$\mathbb{E}[X \mathbf{1}_A] = \nu(A) = \int_A \mathbb{E}[X | \mathcal{G}](\omega) \mu(d\omega) = \mathbb{E}[\mathbb{E}[X | \mathcal{G}] \mathbf{1}_A] < 0$$

ale przecież $X \geq 0 \Rightarrow \mathbb{E}[X \mathbf{1}_A] \geq 0$, więc $A = \emptyset$.

3. Można to zrobić na dwa sposoby: licząc wszystko pokolei, albo można sprawdzić, czy $Y = a\mathbb{E}[X_1 | \mathcal{G}] + b\mathbb{E}[X_2 | \mathcal{G}]$ spełnia warunki wwo tej samej zmiennej co $\mathbb{E}[aX_1 + bX_2 | \mathcal{G}]$. Wówczas obie te zmienne są równe prawie wszędzie.

Warunek \mathcal{G} -mierzalności dla Y jest spełniony, bo Y jest kombinacją liniową dwóch funkcji \mathcal{G} -mierzalnych. Wystarczy więc sprawdzić warunek (W2). W tym celu ustalmy $A \in \mathcal{G}$.

$$\begin{aligned}\mathbb{E}[Y1_A] &\stackrel{*}{=} a\mathbb{E}[\mathbb{E}[X_1 | \mathcal{G}] 1_A] + b\mathbb{E}[\mathbb{E}[X_2 | \mathcal{G}] 1_A] = \\ &= a\mathbb{E}[X_1 1_A] + b\mathbb{E}[X_2 1_A] = \\ &= \mathbb{E}[(aX_1 + bX_2)1_A] = \mathbb{E}[\mathbb{E}[aX_1 + bX_2 | \mathcal{G}] 1_A]\end{aligned}$$

4. Wiemy, że $-|X| \leq X \leq |X|$. Korzystając z punktu 2 dostajemy

$$0 \leq X + |X| \Rightarrow 0 \leq \mathbb{E}[|X| | \mathcal{G}] + \mathbb{E}[X | \mathcal{G}] \Rightarrow -\mathbb{E}[|X| | \mathcal{G}] \leq \mathbb{E}[X | \mathcal{G}]$$

$$0 \leq |X| - X \Rightarrow 0 \leq \mathbb{E}[|X| | \mathcal{G}] - \mathbb{E}[X | \mathcal{G}] \Rightarrow \mathbb{E}[X | \mathcal{G}] \leq \mathbb{E}[|X| | \mathcal{G}]$$

Po złożeniu tych dwóch nierówności:

$$-\mathbb{E}[|X| | \mathcal{G}] \leq \mathbb{E}[X | \mathcal{G}] \leq \mathbb{E}[|X| | \mathcal{G}]$$

wiemy, że $-\mathbb{E}[|X| | \mathcal{G}] \leq \mathbb{E}[X | \mathcal{G}] \leq \mathbb{E}[|X| | \mathcal{G}]$, więc musi być

$$|\mathbb{E}[X | \mathcal{G}]| \leq \mathbb{E}[|X| | \mathcal{G}].$$

5. Zaczniemy od sprawdzenia, że $\mathbb{E}[\mathbb{E}[X | \mathcal{G}_2] | \mathcal{G}_1] = \mathbb{E}[X | \mathcal{G}_1]$. Wybierzmy $A \in \mathcal{G}_1 \subseteq \mathcal{G}_2$:

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}_1] 1_A] = \mathbb{E}[X 1_A] = \mathbb{E}[\mathbb{E}[X | \mathcal{G}_2] 1_A]$$

co potwierdza warunek (W2). \mathcal{G}_1 -mierzalność $\mathbb{E}[X | \mathcal{G}_2]$ jest oczywista, gdyż $\mathcal{G}_1 \subseteq \mathcal{G}_2$, $\mathbb{E}[X | \mathcal{G}_2]$ jest \mathcal{G}_2 -mierzalne, a po obcięciu do \mathcal{G}_1 dostajemy funkcję \mathcal{G}_1 -mierzalną.

Pozostaje nam sprawdzić czym jest $\mathbb{E}[\mathbb{E}[X | \mathcal{G}_1] | \mathcal{G}_2]$. Roboczo nazwiemy $Y = \mathbb{E}[X | \mathcal{G}_1]$. Jest to funkcja \mathcal{G}_1 -mierzalna, ale dzięki $\mathcal{G}_1 \subseteq \mathcal{G}_2$ mamy też \mathcal{G}_2 -mierzalność. W takim razie (tak jak w jednym z przykładów z pierwszego wykładu) $\mathbb{E}[Y | \mathcal{G}_2] = Y$. Pisząc bez używania litery Y dostajemy

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}_1] | \mathcal{G}_2] = \mathbb{E}[X | \mathcal{G}_1]$$

6. Ćwiczenie, a poniżej moja próba.

Jeśli Y jest \mathcal{G} -mierzalne, to $Y\mathbb{E}[X | \mathcal{G}]$ też takie jest jako iloczyn dwóch funkcji \mathcal{G} -mierzalnych. Pozostaje sprawdzić warunek (W2).

Zaczniemy od $Y = \sum a_i 1_{A_i}$ dla $A_i \in \mathcal{G}$, czyli od funkcji prostej. Wybierając $A \in \mathcal{G}$ możemy ograniczyć się do zbiorów A_i , gdyż są one rozłączne i na dowolnym innym zbiorze $Y = 0$. Mamy więc

$$\begin{aligned}\mathbb{E}[\mathbb{E}[XY | \mathcal{G}] 1_A] &\stackrel{(W2)}{=} \mathbb{E}[XY 1_A] = \mathbb{E}[a_i X 1_{A_i}] = a_i \mathbb{E}[X 1_{A_i}] = \\ &= a_i \mathbb{E}[\mathbb{E}[X | \mathcal{G}] 1_{A_i}] = \mathbb{E}[(a_i \mathbb{E}[X | \mathcal{G}]) 1_{A_i}] = \\ &= \mathbb{E}[(Y \mathbb{E}[X | \mathcal{G}]) 1_{A_i}]\end{aligned}$$

Czyli $\mathbb{E}[XY | \mathcal{G}] = Y\mathbb{E}[X | \mathcal{G}]$ dla przypadku gdy Y jest funkcją prostą.

Jeśli teraz Y jest dowolną nieujemną funkcją mierzalną, to istnieje ciąg funkcji prostych

$$s_1 \leq s_2 \leq \dots \leq s_n \leq \dots \quad \lim s_i = Y$$

Wówczas dla dowolnego $A \in \mathcal{G}$

$$\begin{aligned} \mathbb{E}[\mathbb{E}[XY] \mathbf{1}_A] &= \mathbb{E}[XY \mathbf{1}_A] = \mathbb{E}[X \lim s_i \mathbf{1}_A] \stackrel{*}{=} \lim \mathbb{E}[X s_i \mathbf{1}_A] = \\ &\stackrel{**}{=} \lim \mathbb{E}[s_i \mathbb{E}[X | \mathcal{G}] \mathbf{1}_A] = \mathbb{E}[\lim s_i \mathbb{E}[X | \mathcal{G}] \mathbf{1}_A] = \\ &= \mathbb{E}[Y \mathbb{E}[X | \mathcal{G}] \mathbf{1}_A] \end{aligned}$$

* można zrobić na mocy twierdzenia o monotoniczności ciągu s_i dla zwykłej \mathbb{E} , natomiast ** stosuje poprzedni przypadek Y .

Pozostaje przypadek, gdy Y jest dowolną \mathcal{G} -mierzalną zmienną losową. Wówczas możemy rozbić $Y = Y^+ - Y^-$ i skorzystać z liniowości wwo:

$$\mathbb{E}[XY | \mathcal{G}] = \mathbb{E}[XY^+ | \mathcal{G}] - \mathbb{E}[XY^- | \mathcal{G}] = Y^+ \mathbb{E}[X | \mathcal{G}] - Y^- \mathbb{E}[X | \mathcal{G}] = Y \mathbb{E}[X | \mathcal{G}]$$



Twierdzenie 2.5 : o zbieżności i ciągłości.

Niech $\mathcal{G} \subseteq \mathcal{F}$ będzie σ -ciałem, a X, X_1, X_2, \dots będzie ciągiem całkowalnych zmiennych losowych. Wówczas

1. Jeśli $0 \leq X_1 \leq X_2 \leq \dots$ oraz $X_n \nearrow X$, to $\mathbb{E}[X_n | \mathcal{G}] \nearrow \mathbb{E}[X | \mathcal{G}]$ p.w. (twierdzenie o zbieżności monotonicznej)
2. Jeśli $X \geq 0$, to $\mathbb{E}[\liminf_n X_n | \mathcal{G}] \leq \liminf_n \mathbb{E}[X_n | \mathcal{G}]$ (lemat Fatou).
3. Jeśli $|X_n| \leq Y$ oraz Y jest całkowalny i $X_n \rightarrow X$ p.w., to $\mathbb{E}[X_n | \mathcal{G}] \rightarrow \mathbb{E}[X | \mathcal{G}]$ (twierdzenie o zbieżności ograniczonej)

Dowód

1. Zauważamy, że ciąg $\mathbb{E}[X_n | \mathcal{G}]$ jest niemalejący i ograniczony przez $\mathbb{E}[X | \mathcal{G}]$ (na mocy punktu 2 z poprzedniego twierdzenia).

Niech $Y = \lim \mathbb{E}[X_n | \mathcal{G}]$. Wystarczy, że pokażemy $Y = \mathbb{E}[X | \mathcal{G}]$ p.w., czyli sprawdzimy warunki (W1) i (W2). Oczywiście, warunek (W1) wynika z faktu, że granica ciągu funkcji \mathcal{G} -mierzalnych jest nadal \mathcal{G} -mierzalna. Dla sprawdzenia warunku (W2) wybierzmy $A \in \mathcal{G}$

$$\begin{aligned} \mathbb{E}[Y \mathbf{1}_A] &= \mathbb{E}[\lim \mathbb{E}[X_n | \mathcal{G}] \mathbf{1}_A] \stackrel{*}{=} \lim \mathbb{E}[\mathbb{E}[X_n | \mathcal{G}] \mathbf{1}_A] = \\ &= \lim \mathbb{E}[X_n \mathbf{1}_A] = \mathbb{E}[\lim X_n \mathbf{1}_A] = \mathbb{E}[X \mathbf{1}_A] \end{aligned}$$

czyli $Y = \mathbb{E}[X | \mathcal{G}]$ p.w.

2. Zaczniemy od dwóch obserwacji:

🐸 Dla ciągu $\{a_n\}$ $\liminf a_n$ to najmniejszy z jego punktów skupienia, równoważnie:

$$\liminf_n a_n = \lim_{k \rightarrow \infty} \inf_{n \geq k} a_n$$



✿ Dla dowolnej przeliczalnej rodziny zmiennych losowych $\{Z_n\}_{n \in T}$ i dla dowolnego $t \in T$ mamy

$$\inf_{s \in T} Z_s \leq Z_t$$

$$\mathbb{E} \left[\inf_{s \in T} Z_s \right] \leq \mathbb{E} [Z_t]$$

$$\mathbb{E} \left[\inf_{s \in T} Z_s \right] \leq \inf_{t \in T} \mathbb{E} [Z_t]$$

(co jest tak naprawdę wersją lematu Fatou dla \mathbb{E} z RP1R).

Stosując obserwację  w przejściach \star , obserwację  w przejściu $\star\star$ oraz pkt 1. ($\inf_{n>k} X_n \leq \inf_{n>k+1} X_n$) w $\star\star\star$, dostajemy

$$\begin{aligned} \mathbb{E} \left[\liminf_n X_n \mid \mathcal{G} \right] &\stackrel{\star}{=} \mathbb{E} \left[\liminf_{n>k} X_n \mid \mathcal{G} \right] \stackrel{\star\star\star}{=} \lim_k \mathbb{E} \left[\inf_{n>k} X_n \mid \mathcal{G} \right] \leq \\ &\stackrel{\star\star}{\leq} \lim_k \inf_{n>k} \mathbb{E} [X_n \mid \mathcal{G}] \stackrel{\star}{=} \liminf_n \mathbb{E} [X_n \mid \mathcal{G}] \end{aligned}$$

3. Rozważmy zmienne $X'_n = Y + X_n$. Ponieważ $|X_n| \leq Y$, to $Y + X_n \geq 0$.

$$\begin{aligned} \mathbb{E} [Y + \liminf X_n \mid \mathcal{G}] &= \mathbb{E} [\liminf (X_n + Y) \mid \mathcal{G}] \stackrel{3.}{\leq} \liminf \mathbb{E} [Y + X_n \mid \mathcal{G}] = \\ &= \mathbb{E} [Y] + \liminf \mathbb{E} [X_n \mid \mathcal{G}] \end{aligned}$$

To daje nam, że $\mathbb{E} [\liminf X_n \mid \mathcal{G}] \leq \liminf \mathbb{E} [X_n \mid \mathcal{G}]$.

Postępując analogicznie dla $X_n'' = Y - X_n$ (które dalej jest ≥ 0) dostaniemy $\mathbb{E} [\limsup X_n \mid \mathcal{G}] \geq \limsup \mathbb{E} [X_n \mid \mathcal{G}]$:

$$\begin{aligned} \mathbb{E} [Y - \limsup X_n \mid \mathcal{G}] &= \mathbb{E} [\limsup (Y - X_n) \mid \mathcal{G}] = \\ &= -\mathbb{E} [\liminf (X_n - Y) \mid \mathcal{G}] \stackrel{3.}{\geq} -\liminf \mathbb{E} [X_n - Y \mid \mathcal{G}] = \\ &= \limsup \mathbb{E} [Y - X_n \mid \mathcal{G}] \end{aligned}$$

Ale wiemy, że $\liminf X_n = X$ oraz $\limsup X_n = X$, czyli

$$\liminf \mathbb{E} [X_n \mid \mathcal{G}] \geq \mathbb{E} [\liminf X_n \mid \mathcal{G}] = \mathbb{E} [X \mid \mathcal{G}] = \mathbb{E} [\limsup X_n \mid \mathcal{G}] \geq \limsup \mathbb{E} [X_n \mid \mathcal{G}]$$

ale przecież $\liminf \mathbb{E} [X_n \mid \mathcal{G}] \leq \limsup \mathbb{E} [X_n \mid \mathcal{G}]$, czyli musi być

$$\liminf \mathbb{E} [X_n \mid \mathcal{G}] = \mathbb{E} [X \mid \mathcal{G}] = \limsup \mathbb{E} [X_n \mid \mathcal{G}]$$


i ponieważ $\liminf = \limsup = \lim$ to mamy


$$\lim \mathbb{E} [X_n \mid \mathcal{G}] = \mathbb{E} [X \mid \mathcal{G}].$$




Twierdzenie 2.6.

Niech $\mathcal{G} \subseteq \mathcal{F}$ będzie σ -ciałem. Załóżmy, że

 X jest \mathcal{G} -mierzalna

 Y jest niezależna od \mathcal{G}

 funkcja $\psi : \mathbb{R}^2 \rightarrow \mathbb{R}$ jest mierzalna taka, że

$$\mathbb{E} [\psi(X, Y)] < \infty.$$

Wówczas

$$\mathbb{E} [\psi(X, Y) \mid \mathcal{G}] = \Psi(X),$$

gdzie funkcja $\Psi : \mathbb{R} \rightarrow \mathbb{R}$ jest zdefiniowana jako $\Psi(X) = \mathbb{E} [\psi(X, Y)]$.

Dowód

Jeśli $\psi(x, y) = xy$, to korzystając z punktu 3. twierdzenia 2.4 dostajemy

$$\psi(x) = \mathbb{E} [xY] = x\mathbb{E} [Y]$$

